

IV Simpósio de Métodos Numéricos em Engenharia
UFPR, Curitiba, 2019

Reconstrução de Refletividade de Radar Utilizando Rede Neural Convolucional

Camila de Oliveira
Paulo Alexandre da Silva Mello
Prof^o Dr^o Sergio Scheer
Universidade Federal do Paraná
Curitiba-PR, Brasil

Cesar Beneti
SIMEPAR-Tecnologia e Monitoramento Ambiental do Paraná
Curitiba-PR, Brasil

Resumo—Eventos de tempestades severas podem causar grande destruição e danos à população. Analisar a estrutura desses sistemas ajuda a identificar as condições favoráveis para sua geração, contribuindo para técnicas específicas de previsão. Uma maneira de observar essas tempestades é através do radar meteorológico. No entanto, os radares podem possuir resolução temporal muito grande comparada com o tempo de evolução de uma tempestade, não permitindo observar sua completa evolução através desses dados. Esse trabalho utiliza uma rede neural convolucional para criar imagens sintéticas de refletividade de radar. Os resultados estimados pela rede apresentaram em geral, valores abaixo dos observados pelo radar meteorológico, mas forneceram uma boa estimativa das regiões de chuvas.

Palavras-chave—radar meteorológico; refletividade sintética; rede neural convolucional.

I. INTRODUÇÃO

A meteorologia é definida como a ciência que estuda os fenômenos que ocorrem na atmosfera. Esses fenômenos estão relacionados com o estado físico, dinâmico e químico da atmosfera, e a superfície terrestre subjacente. Desta forma, a meteorologia busca compreender de forma abrangente os fenômenos atmosféricos que são presenciados no cotidiano [1]. As aplicações da meteorologia são bastante amplas e a previsão do tempo influencia o cotidiano de toda a sociedade.

Eventos de vendavais, granizos e tornados, ainda que relativamente raros em comparação com outros sistemas meteorológicos (como chuvas frontais), representam ameaça potencial para atividades importantes como por exemplo defesa civil, aviação, agricultura e transmissão e distribuição de energia elétrica. Assim, o fato de serem eventos relativamente raros não implica em darmos menos atenção ao estudo destes sistemas e

ao treinamento de pessoal operacional visando a previsão dos mesmos [2].

A intensidade e a frequência das tempestades convectivas dependem muito da região geográfica e das condições atmosféricas. No Brasil, a maior incidência de eventos severos é observada nas Regiões Sul e Sudeste, inclusive com registro de tornados na Região Sul. A alta frequência de eventos severos nesta região deve-se principalmente ao escoamento atmosférico, que frequentemente se apresenta na forma do Jato de Baixos Níveis, promovendo o transporte de calor e umidade da Região Amazônica para regiões subtropicais e de latitudes médias [3].

Estudar a estrutura dessas tempestades severas ajuda a identificar as condições favoráveis para a sua formação, podendo-se assim, com antecedência de várias horas, vincular alertas e antecipar a adoção de estratégias que eliminem ou minimizem o impacto negativo destes fenômenos meteorológicos.

A estrutura tridimensional de uma tempestade pode ser observada utilizando o radar meteorológico. O radar é uma das tecnologias mais precisas e utilizadas dentro da meteorologia, sendo capaz de prover informações complexas sobre as dimensões horizontal e vertical da precipitação. Quando utilizado em conjunto com um experimento de medição de taxa de precipitação, permite o levantamento adequado do comportamento local da chuva [4].

Porém, a coleta de dados pelo radar pode acontecer em um intervalo relativamente grande para o estudo de tempestades, que podem se desenvolver e dissipar num tempo inferior ao da coleta dos dados. Como também, podem ocorrer falhas na coleta de dados do radar por algum período de tempo, dificultando até a previsão de deslocamento de tempestades de

curto prazo.

Este trabalho tem como objetivo fazer a reconstrução da refletividade, para serem utilizadas nos períodos em que os dados de radar não estão disponíveis. Essas imagens são obtidas através de uma rede neural convolucional, treinada a partir de dados de Descargas Elétricas Atmosféricas (DEA). As descargas elétricas são utilizadas pois estão fortemente relacionadas à precipitação intensa.

A seguir serão apresentados alguns conceitos de radar meteorológico e de Descargas Elétricas Atmosféricas. Na seção IV são descritos os dados utilizados. Na seção V é descrita a rede neural convolucional utilizada nesse trabalho. Na seção VI são apresentados a descrição dos dados utilizados e por fim, são apresentados os resultados, discussões e conclusão.

II. RADAR METEOROLÓGICO

Radares são dispositivos que permitem detectar objetos a longas distâncias. Um radar meteorológico consiste basicamente de quatro componentes principais: um transmissor para gerar um sinal de alta frequência, uma antena para enviar o sinal e receber o eco de volta do alvo, um receptor para detectar e amplificar o sinal, e algum tipo de sistema de exibição para permitir que se veja o que o radar detectou [5].

Normalmente, a coleta de dados de radar se dá através da rotação da antena em torno de um eixo vertical com uma sequência pré-programada de varreduras azimutais em 360°. Um volume de varredura corresponde a uma sequência completa de várias varreduras azimutais com diferentes elevações da antena.

Esses dados possuem coordenadas esféricas com três graus de liberdade (r, θ, ϕ), onde r é a distância do alvo até o radar (*slant range*), θ é o ângulo de azimute em relação ao norte e, ϕ é o ângulo de elevação da antena em relação ao horizonte.

Os dados de refletividade utilizados são provenientes do radar instalado em Cascavel – PR operado pelo instituto tecnológico SIMEPAR. No modo volumétrico, ele cobre um círculo com raio de 240 km, alcançando parte leste do Paraguai, extremo nordeste da Argentina, sul do Mato Grosso do Sul e noroeste do Estado de Santa Catarina. Ele monitora chuvas e ventos em intervalos de tempo de 5 minutos e é capaz de identificar tempestades severas. Seus dados são utilizados para fazer estimativa de chuva e previsão de deslocamento de tempestades em curtíssimo prazo de tempo.

A. Refletividade

Uma das variáveis obtidas pelo radar é a refletividade (z), a qual será utilizada neste trabalho.

A refletividade é o fator entre as ondas eletromagnéticas emitidas e as que voltam para o radar, depois de passarem por uma nuvem e serem irradiadas em todas as direções pelas gotas

de chuva. Quanto maior o valor da refletividade, maiores são os diâmetros das gotas presentes, e maior será a intensidade da precipitação. Seu valor pode ser expresso por:

$$z = \sum_{vol} D^6, \quad (1)$$

onde D é o diâmetro da gota e o somatório é feito sobre o número total de gotas de tamanhos variados dentro de uma unidade de volume de feixe (*bin*). Sua unidade é expressa em mm^6m^{-3} .

A refletividade pode variar desde valores próximos de $0,001 \text{ mm}^6\text{m}^{-3}$ (névoa úmida) até $36.000.000 \text{ mm}^6\text{m}^{-3}$ (granizo grande ~ 5 a 10 cm). Por isso, é conveniente utilizar sua representação em uma escala logarítmica:

$$Z = 10 \log \left(\frac{z}{1 \text{ mm}^6\text{m}^{-3}} \right), \quad (2)$$

onde Z é o valor de refletividade em escala logarítmica, medida em dBZ, e z é o valor de refletividade em escala linear (mm^6m^{-3}).

B. Produtos do Radar

Os dados em formato numérico obtidos pelo radar podem ser convertidos em imagens, chamadas de produtos do radar. Esses produtos podem ser visualizados de diferentes modos. Dois dos mais importantes são o PPI e ZMAX, que serão descritos a seguir.

1) *PPI*: O PPI (*Plan Position Indicator*) é o produto gerado de uma varredura em azimute. Ele representa a projeção, no plano horizontal, dos dados dos ecos recebidos em um ângulo de elevação constante. Esses dados em coordenadas esféricas são transformados para coordenadas cartesianas e então, são plotados com o centro da imagem indicando a localização do radar.

A Fig. 1 apresenta uma varredura em azimute do radar com um determinado ângulo de elevação ϕ constante e a Fig. 2 mostra o PPI da variável refletividade obtida pelo radar através desta varredura em azimute. As cores quentes representam valores de refletividade mais elevados, enquanto que cores frias representam valores mais baixos.




Figura 1: Exemplo de varredura do radar com elevação ϕ da antena constante.

2) *ZMAX - Máxima Refletividade da Coluna*: O ZMAX indica o maior valor de refletividade encontrado em cada coluna do volume de varredura. Ou seja, para cada posição (r, θ) dos dados do radar, encontra-se o maior valor de refletividade em todas as elevações do volume de varredura, como ilustrado na Fig. 3.

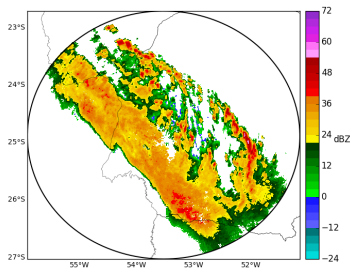


Figura 2: PPI obtido da variável refletividade desta varredura.




Figura 3: Produto ZMAX.

III. DESCARGAS ELÉTRICAS ATMOSFÉRICAS

Descargas atmosféricas são descargas elétricas de grande intensidade (pico de corrente – valor máximo atingido pela corrente – acima de um quiloampere (kA)) e de grande extensão (alguns quilômetros). Inicia-se quando é excedida a capacidade isolante (ou rigidez dielétrica) do ar pelo campo elétrico gerado pelo acúmulo de cargas elétricas em regiões localizadas na atmosfera. Quebrada a rigidez dielétrica do ar, elétrons de uma região de cargas negativas movem-se para uma região de cargas positivas [6].

As descargas podem se apresentar de diferentes formas, interagindo com o solo, ou apenas como um fenômeno luminoso no céu. E, apesar da descarga parecer contínua, geralmente é composta por múltiplas descargas, que ocorrem em intervalos de tempo muito curtos.

Descargas Elétricas Atmosféricas estão fortemente relacionadas à precipitação intensa. A relação da precipitação com as descargas pode variar com relação ao tipo de tempestade, estação do ano e localidade na qual o estudo é realizado [7].

Os dados utilizados no trabalho são provenientes da Rede Integrada Nacional de Detecção de Descargas Atmosféricas (RINDAT). Seu Sistema de Detecção e Localização de Descargas Atmosféricas gera pesquisa científica e produtos destinados a aplicações na previsão de tempo, na análise e manutenção de sistemas elétricos de transmissão, de distribuição e na emissão de laudos de análise de eventos severos para seguradoras e empresas de engenharia [8].

Entre os produtos de visualização gerados pelo sistema se destacam a localização geográfica e temporal de descargas atmosféricas nuvem-terra, localização de temporais e determinação de características de descargas como por exemplo, o valor estimado do pico da corrente de retorno, polaridade e número de componentes (multiplicidade) se a descarga for de natureza múltipla.

A precisão das informações de localização de raios do sistema é, em média, de 500 metros dentro do perímetro definido pela posição das estações remotas de recepção. O sistema opera através do Sistema de Posicionamento Global (*Global Positioning System* - GPS), o qual proporciona informações de temporização de raios com resoluções de até 300 nanossegundos [8].

IV. DADOS

Utilizou-se o produto ZMAX dos dados de refletividade, que foram filtrados para eliminar valores inferiores a 20 dBZ. Em seguida, esses dados foram interpolados para uma grade regularmente espaçada com resolução horizontal de 3x3 km e resolução temporal de 5 minutos (intervalo mínimo de monitoramento disponível).

A mesma resolução espacial e temporal foi utilizada nos dados de descargas elétricas, onde, para cada ponto de grade, foram atribuídos o número acumulado de descargas ocorridas no seu interior e a polaridade dessas descargas.

Foram selecionados dados de chuvas na área do radar de Cascavel para o período de 01/01/2018 a 01/11/2019. Esses dados foram divididos em três partes: 50 % para o treinamento, 20 % para validação e 30 % para teste da rede apresentada a seguir.

V. REDE NEURAL CONVOLUCIONAL

Uma Rede Neural Convolutacional (*Convolutional Neural Network* - CNN) é uma variação das redes de Perceptrons de Múltiplas Camadas (*MultiLayer Perceptron* – MLP), tendo sido inspirada no processo biológico de processamentos de dados visuais. De maneira semelhante aos processos tradicionais de visão computacional, uma CNN é capaz de aplicar filtros em dados visuais, mantendo a relação de vizinhança entre os *pixels* da imagem ao longo do processamento da rede. Este tipo de rede vem sendo amplamente utilizada, principalmente nas aplicações de classificação, detecção e reconhecimento em imagens e vídeos [9].

Uma CNN pode ser dividida em duas partes: extração de características pelas camadas convolucionais e uma rede neural tradicional (neste trabalho, foi utilizado MLP).

As convoluções são operações entre matrizes, que são aplicadas diversas vezes em diferentes regiões da imagem, alterando a representação dos dados e aprendendo os filtros.

Os pesos dos filtros são calculados automaticamente e cada filtro aprendido é um extrator de características.

Para a camada de entrada da rede, foram utilizados os dados das descargas elétricas atmosféricas (densidade de raios e polaridade).

A arquitetura da CNN utilizada possui três camadas de convolução onde todas utilizam filtro 3x3 tamanho 32, 64 e 128, respectivamente. Cada camada de convolução possui uma camada de *max-pooling* que diminui a matriz de convolução de cada etapa, pegando o maior valor de cada matriz de convolução (utiliza filtros 2x2 e possuem o mesmo tamanho das camadas de convolução).

Após a etapa de extração de característica, a matriz foi transforada para unidimensional obtendo 102400 variáveis de representação.

A última etapa é a aplicação da MLP, que contém uma rede densa de 512 neurônios e a camada de saída tem 25600 valores, que representam a figura de refletividade.

VI. RESULTADOS E DISCUSSÕES

Após o treinamento e validação da CNN foi analisado se houve qualquer problemas de *overfitting* pela rede. O *overfitting* é quando, uma rede neural, decora a sua base de dados, dessa forma, perde o poder de generalização. É possível avaliar essa situação, gerando um gráfico da função de perda (*loss*) do treinamento e validação. Se as linhas divergem, há um problema de *overfitting* e quando decaem em conjunto, a rede está aprendendo. No caso da CNN criada, não houve problemas de *overfitting*, como mostra a Fig. 4, pois essa divergência entre o treinamento e a validação, tem tendência de ocorrer acima de 100 *epochs*, o que não foi o caso dessa rede.




Figura 4: Gráfico de aprendizagem.

Os resultados obtidos pela CNN foram avaliados através de (3), (4) e (5), onde N é a quantidade de amostras, y são os dados estimados e x são os dados observados. Foi utilizado

também o coeficiente de correlação entre os dados estimados e observados, que descreve a associação ou dependência entre as duas variáveis, onde os valores variam entre 0 e 1 e quanto mais próximo de 1, maior a correlação. Os resultados são apresentados na Tab. I.

$$\text{BIAS} = \frac{\sum_{i=1}^n (y_i - x_i)}{N}, \quad (3)$$

$$\text{MAE} = \frac{\sum_{i=1}^n |y_i - x_i|}{N}, \quad (4)$$

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - x_i)^2}, \quad (5)$$

Tabela I: Valores dos erros e correlação calculados entre os valores estimados e observados.

BIAS	-0.42
MAE	4.53
RMSE	7.47
Correlação	0.75
R ² (Coeficiente de Determinação)	0.17

O BIAS negativo indica que os dados estimados de refletividade estão abaixo dos valores observados, como pode ser visto nas Fig. 7-5.

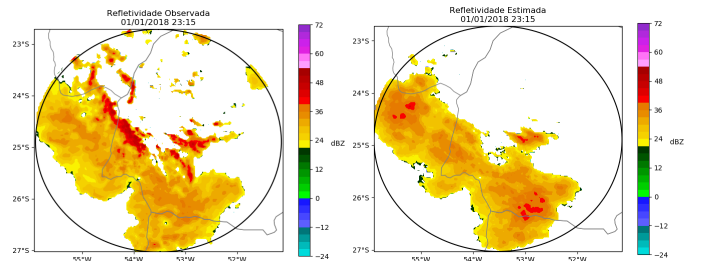


Figura 5: Comparação entre refletividade observada (esquerda) e estimada (direita) para o dia 01/01/2018 às 23:15.

VII. CONCLUSÕES

Os resultados obtidos pela CNN fornecem uma boa estimativa das regiões de chuva na área do radar, apesar das intensidade dos valores de refletividade serem mais baixas.

Esses valores mais baixos de refletividade mostram que, para trabalhos futuros, deve-se obter mais características que possam melhorar a reconstrução de refletividade, devido ao

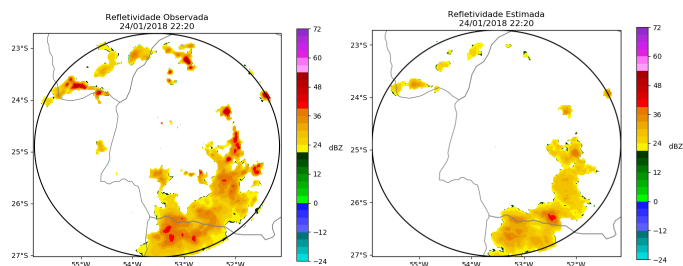


Figura 6: Comparação entre refletividade observada (esquerda) e estimada (direita) para o dia 24/01/2018 às 22:40.

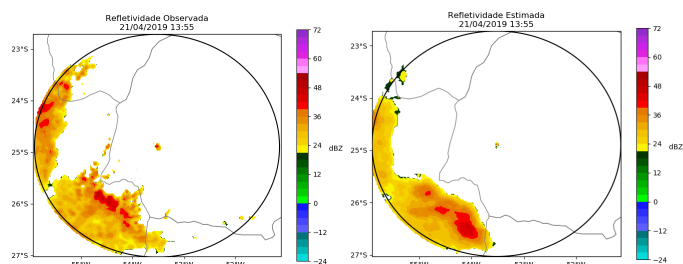


Figura 7: Comparação entre refletividade observada (esquerda) e estimada (direita) para o dia 24/04/2019 às 13:55.

problema não ser linear e apenas duas características não serem suficiente.

REFERÊNCIAS

- [1] R. H. L. Seluzniak. Controle de qualidade de dados de radar polarmétrico com apoio de visualizador interativo de dados. Master's thesis, Universidade Federal do Paraná, 2016.
- [2] E. L. Nascimento. Previsão de tempestades severas utilizando-se parâmetros convectivos e modelos de mesoescala: Uma estratégia operacional adotável no Brasil? *Revista Brasileira de Meteorologia*, 20(1):121–140, 2005.
- [3] G. C. J. Escobar H. R. Pinheiro and K. M. Andrade. Aplicação de uma ferramenta objetiva para previsão de tempo severo em ambiente operacional. *Revista Brasileira de Meteorologia*, 29(2):209–228, 2014.
- [4] C. Oliveira. Identificação e correção da banda brilhante em dados de radar meteorológico. Master's thesis, Universidade Federal do Paraná, 2014.
- [5] R. E. Rinehart. *Radar for meteorologists*. Rinehart Publications, Nevada, United States of America, 4 edition, 2004.
- [6] Mariana Kleina. *Identificação, Monitoramento e Previsão de Tempestades Elétricas*. PhD thesis, Universidade Federal do Paraná, 2015.
- [7] W. F. Coelho. Avaliação das estimativas de precipitação e refletividade geradas a partir de descargas elétricas atmosféricas. Master's thesis, Universidade Federal de Pelotas, 2019.
- [8] Rindat, <<http://www.rindat.com.br>>, Nov 2019.
- [9] Ana Caroline Gomes Vargas, Aline Paes, and Cristina Nader Vasconcelos. Um estudo sobre redes neurais convolucionais e sua aplicação em detecção de pedestres. In *XXIX Conference on Graphics, Patterns and Images*, 2016.